Fakultet elektrotehnike, računarstva i informacijskih tehnologija Osijek

Računarstvo usluga i analiza podataka

SEMINARSKI RAD

„Predviđanje padalina“

Filip Krpes

Osijek, 2025.

Sadržaj

1. Uvod 1
2. Opis problema 1
2.1. Korišteni podaci 2
2.2. Korišteni postupci strojnog učenja 3
3. Opis programskog rješenja 3
3.1. Model strojnog učenja 3
3.2. Način korištenja API-ja 6
3.3. Klijentska aplikacija 7
4. Zaključak 9
5. Poveznice i literatura 9

1. Uvod

Predikcija vremenskih uvjeta je bitna za sva područja društva od poljoprivrede, prijevoza dobara, turizma do svakodnevnog života. Ovaj značajni proces je složen i zahtjeva konstantna i mnogobrojna mjerenja po cijelom svijetu koristeći bazne stanice, satelite, meteoroloških balona i sl. kako bi se razvili pojednostavljeni modeli koji bi mogli predvidjeti vremenske uvjete. Zbog velikog broja parametara koji utječu na vrijeme i ograničenog broja mjerenja ovaj proces je složen i zahtjeva složene proračune koji samo približe opisuju stvarne pojave. Zbog stalnih promjena u vremenu exponencialno je teže predvidjeti vrijeme na duže periode, stoga nije moguće predvidjeti meteorološke uvijete više nego nekoliko dana unaprijed.

Korištenjem strojnog učenja i njegovih sposobnosti obrade podataka, prepoznavanja obrazaca i donošenje predikcija pokušava se pružati brža i jednostavnija alternativa klasičnim metodama predikcije vremena.

Cilj projektnog zadatka je izraditi korisničku aplikaciju za predviđanje padalina jedan dan unaprijed. Koriste se podaci prošlih vremenskih pojava za treniranje nekoliko modela strojnog učenja koristeći uslugu Microsoft Azure. Od zadanih modela odabrat će se najprikladniji za dani zadatak. Uz to cilj je stvoriti i implementirati API (aplikacijsko programsko sučelje) koji koristi model strojnog učenja u sklopu aplikacije kako bi predvidio hoće li biti padalina ili ne.

2. Opis problema

Predikcija padalina je složen postupak jer padaline ovise o velikom broju meteoroloških i ne meteoroloških pojava. Kao i kod klasičnih metoda predviđanja padalina, korištenjem strojnog učenja i dalje imamo slična ograničenja. Glavno ograničenje je ne stabilnost vremena tj. što dalje u budućnost gledamo to je vrijeme teže za predvidjeti. Stoga predviđanje više od nekoliko dana unaprijed je neprecizno. Također je potrebno primijetiti kako neke vremenske prilike se pojavljuju iznenada i lokalizirano što otežava njihovu predikciju.

U kontekstu izrade samog modela predikcije padalina jedan od značajnijih izazova jest odabir prikladnih podataka za treniranje. Opservacijski podaci s kojim se trenira model sadrže često nedostajuće vrijednosti. Uz nedostajuće podatke problem mogu predstaviti različiti načini mjerenja, kalibracija uređaja za mjerenje ili šum tijekom mjerenja. Ovi problemi se mogu riješiti predobradom podataka kao što su izbacivanje iznimno velikih ili malih vrijednosti i uklanjanje nedostajućih vrijednosti. Potrebno je i normalizirati neke od podataka kao npr. podaci o tlaku jer su značajno veći od drugih. Ovo je potrebno kako model ne bi pridijelio varijablama tlaka veću značajnost u predikciji samo zbog većeg broja. Završno je bitno napomenuti kako je bitno raditi predikciju padalina za određenu regiju. Jer padaline ovise o ne mjerivim parametrima kao što su specifične geografske formacije ili vodene mase, sustav koji je treniran na podacima jedne regije bio bi manje precizan u predikciji padalina druge regije.

2.1. Korišteni podaci

Skup podataka korišten za treniranje modela strojnog učenja sastoji se od dnevnih mjerenja vremenskih uvjeta provedenih tijekom perioda od deset godina u raznim mjestima u Australiji. Pohranjeni su u obliku .csv datoteke gdje prvi red predstavlja zaglavlja pojedinih stupaca a ostali redovi su pojedini zapisi čije komponente su odvojene zarezom. Podaci se sastoje od mjesta i vremena mjerenja kao i mjerenja temperature, tlaka zraka, količine padalina, razine isparavanja, razine oblačnosti, brzini i smjeru vjetra. Svaki od dnevnih mjerenja završava s informacijom dali je u sljedećih 24 sati padala kiša i dali je dan poslije padala kiša. Za potrebe ovog rada nisu potrebne informacije o mjestu i vremenu mjerenja te će se samo promatrati i pokušati predvidjeti hoće li padati kiša u sljedećih 24 sata. Time imamo 19 značajki kojima ćemo trenirati model i 1 binarnu variablu koju želimo predvidjeti tj. ima li padalina u idućih 24 sata.

	Date	Location	MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine	WindGustDir	WindGustSpeed	WindDir9am	...	Humidity9am	Humidity3pm	Pressure9am	Pressure3pm	Cloud9am	Cloud3pm	Temp9am	Temp3pm	RainToday
0	2008-12-01	Albury	13.4	22.9	0.6	NaN	NaN	W	44.0	W	...	71.0	22.0	1007.7	1007.1	8.0	NaN	16.9	21.8	No
1	2008-12-02	Albury	7.4	25.1	0.0	NaN	NaN	WNW	44.0	NNW	...	44.0	25.0	1010.6	1007.8	NaN	NaN	17.2	24.3	No
2	2008-12-03	Albury	12.9	25.7	0.0	NaN	NaN	WSW	46.0	W	...	38.0	30.0	1007.6	1008.7	NaN	2.0	21.0	23.2	No
3	2008-12-04	Albury	9.2	28.0	0.0	NaN	NaN	NE	24.0	SE	...	45.0	16.0	1017.6	1012.8	NaN	NaN	18.1	26.5	No
4	2008-12-05	Albury	17.5	32.3	1.0	NaN	NaN	W	41.0	ENE	...	82.0	33.0	1010.8	1006.0	7.0	8.0	17.8	29.7	No

Slika 1: Neobrađeni skup podataka

Podaci sadrže preko 100 tisuća mjerenja, ali nisu sva mjerenja iskoristiva. Više od pola svih mjerenja ne sadrže vrijednosti za razinu isparavanja i broj sati koje je bilo sunčano toga dana, kao i razinu oblačnosti toga dana. Prije treniranja modela mjerenja s nedostajućim podacima su uklonjeni korištenjem python skripte i alata pandas. Nakon uklanjanja nepotpunih mjerenja ostalo je 25 tisuća mjerenja koja su i dalje dovoljna za treniranje modela.

```
import pandas as pd

df = pd.read_csv("weatherAUS.csv")

df_clean = df.dropna()

df_clean = df_clean.reset_index(drop=True)

df_clean.to_csv("weather_clean.csv", index=False)

print(f"Original dataset shape: {df.shape}")
print(f"Cleaned dataset shape: {df_clean.shape}")
```

```
Original dataset shape: (76113, 23)
Cleaned dataset shape: (25579, 23)
```

Slika 2: Uklanjanje nepotpunih mjerenja

Date	Location	MinTemp	MaxTe...	Rainfall	Evaporation	Sunshine	WindGustDir	WindG...	WindDi...	WindDi...	WindSpeed9am
2009-01...	Cobar	17.9	35.2	0	12	12.3	SSW	48	ENE	SW	6
2009-01...	Cobar	18.4	28.9	0	14.8	13	S	37	SSE	SSE	19
2009-01...	Cobar	19.4	37.6	0	10.8	10.6	NNE	46	NNE	NNW	30

Slika 3: Isječak očišćenih podataka unutar Microsoft Azure

2.2. Korišteni postupci strojnog učenja

Prije početka treniranja modela numerički podaci su prvo normalizirani kako variable kao tlak zraka koji se sastoje od velikih brojeva ne bi više utjecali na finalnu predikciju od drugih. Zatim se podaci dijele na trening skupinu i skupinu za testiranje kojom će se provjeriti točnost sustava nakon treniranja. S obzirom na to da se problem predviđanja padalina svodi na problem klasifikacije s 2 klase bira se 5 algoritama za treniranje koji su pogodni za binarnu klasifikaciju. Odabrani algoritmi su "Two-Class Support Vector Machine", "Two-Class Average Perceptron", "Two-Class Decision Forest", "Two-Class Logistic Regression" i "Two-Class Boosted Decision Tree".Model se trenira da nauči veze između mjerenja vremenskih uvjeta i izlazne variable tj. hoće li padati kiša. Ovo se čini kako bi model mogao odrediti klasu tj. ishod ovisno o novim mjerenja koje do tada još nije vidio. Svaka predikcija je vrijednost od 0 do 1 i rezultat se interpretira kao jedno od dvije klase ovisno kojem broju je bliža predikcija. Od pet odabranih algoritama za treniranje bit će odabran onaj za izradu API-a koji ima najveću točnost u predikciji stanja padalina. Ovo se može vidjeti nakon testiranja modela u "score" modulu.

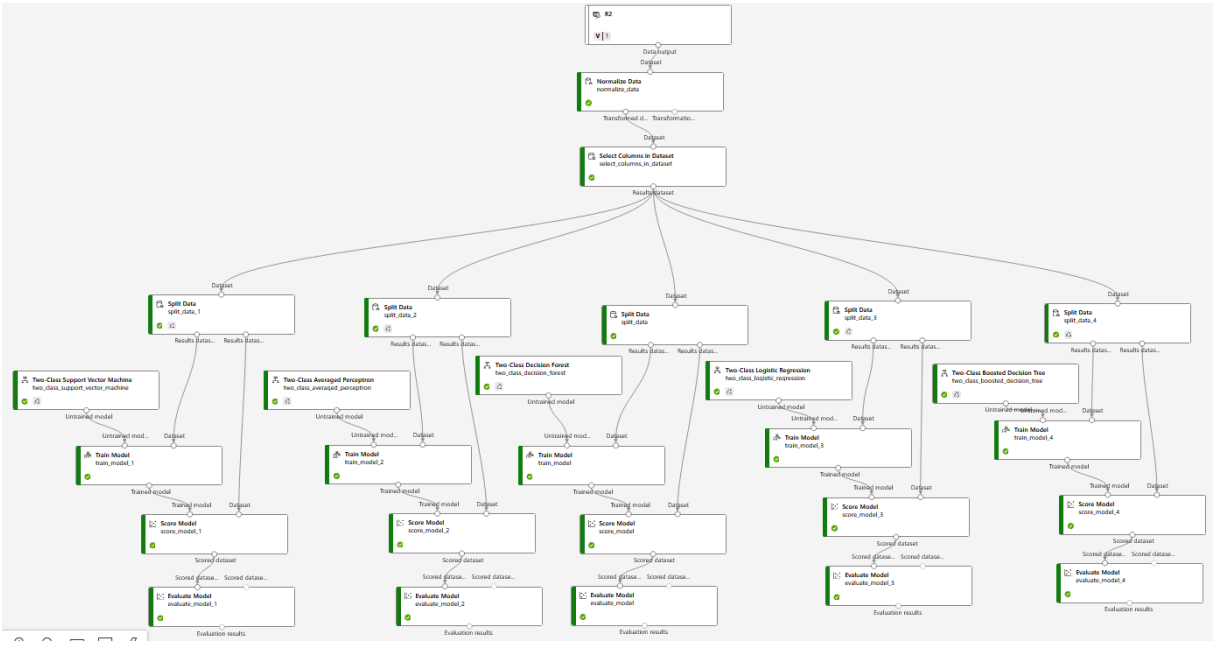
3. Opis programskog rješenja

Opis cjelokupnog programskog rješenja zajedno s načinom korištenja, screenshotovima i specifičnim/ključnim segmentima koda.

3.1. Model strojnog učenja

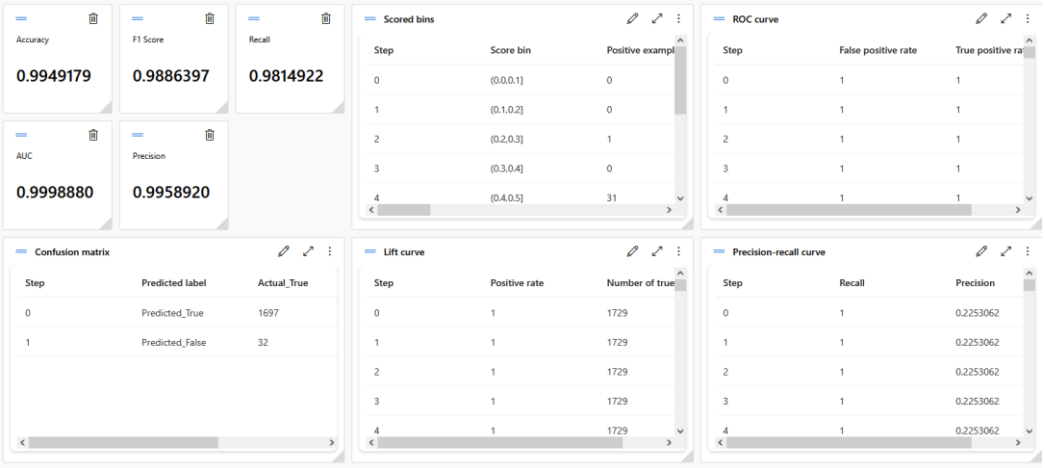
Prikaz modela koji je korišten, argumentacije zašto je odabran baš taj, provedene usporedbe između više njih kako bi se odabrao najbolji.

Za treniranje modela korišten je "Microsoft Azure Machine Learning Studio". To je Microsoftova platforma u oblaku za izgradnju, učenje, implementaciju i upravljanje modelima strojnog učenja. Modeli su se izradili u designer dijelu servisa koji omogućuje korištenje gotovih blokova za izradu sustava strojnog učenja. Modeli su uspoređeni blokom za evaluaciju i po tim rezultatima se bira model koji će biti implementiran u API.



Slika 4: Modeli strojnog učenja

Na slici 4 vidimo implementirane modele strojnog učenja. Počinjemo od bloka za unos podataka u kojem se nalazi naša baza meteoroloških mjerenja koja je uvedena u „Microsoft Machine Learning Studio" kao tablica podataka. Nedostajući podaci su u ovom trenutku već uklonjeni. Zatim blokom za normaliziranje svodimo numeričke podatke na raspone koji su sličniji a time lakši za obradit i omogućuju veću preciznost. Stupci za vrijeme i mjesto mjerenja su još uvijek u podacima stoga se koristi blok selektor kako bi zanemario ta dva stupca tablice. Obrađeni podaci idu dalje na blok za podjelu na training skup i testni skup. Svaki model ima svoj blok podjele podatka zbog preglednosti cijelog sustava ali bio je dovoljan samo jedan. Sljedeće modeli se treniraju sa 70 % podataka u training skupu i zatim se provjerava točnost predikcija modela u bloku za ocjenjivanje. Na kraju se evaluiraju dobiveni rezultati u bloku za evaluaciju i radi se statistička analiza i grafički prikaz.



Slika 5: Metrike za evaluaciju modela

Na slici 5 vidimo kriterij za evaluaciju binarnih klasifikacijskih modela u „ Microsoft Machine Learning Studio”. Oni su:

- Točnost („accuracy”) - udio točnih predviđanja
- Preciznost („precision”) - od svih predviđenih pozitivnih rezultata, koliko ih je zapravo bilo pozitivnih
- Osjetljivost („sensitivity”) -stopa stvarnih pozitivnih rezultata, od svih stvarnih pozitivnih rezultata koliko ih je model ispravno identificirao
- F1 rezultat - harmonijska sredina preciznosti i osjetljivosti.
- AUC - površina ispod ROC krivulje

  (ROC = prikazuje stopu stvarnih pozitivnih rezultata u odnosu na stopu lažno pozitivnih rezultata)

	Accuracy	F1 Score	Recall	AUC	Precision
Support Vector Machine	0.994918	0.988640	0.981492	0.999888	0.995892
Averaged Perceptron	0.946052	0.868404	0.790052	0.974142	0.964009
Decision Forest	0.999479	0.998845	1.000000	0.999998	0.997692
Logistic Regression	0.999479	0.998845	1.000000	0.999998	0.997692
Boosted Decision Tree	1.000000	1.000000	1.000000	1.000000	1.000000

Slika 6: Usporedba algoritama za binarnu klasifikaciju

Na slici 6 vidimo kako svi algoritmi imaju odlične rezultate. Ovo se čini ne realistično i može biti do više faktora. Jedan od mogućih razloga je što 76% mjerenja je jedne klase tj za 76% mjerenja vrijedi da neće padati kiša. Druga mogućnost je ukoliko jedan od nezavisnih variabli kao npr. količina padalina direkto iskazuje o kojo se klasi radi bez potrebe učenja modela.

	Model	Accuracy	AUC	F1 Score	Precision	Recall
0	Support Vector Machine	0.762598	0.839226	0.771350	0.747253	0.797053
1	Averaged Perceptron	0.726256	0.811838	0.717142	0.745662	0.690723
2	Decision Forest	0.846303	0.922996	0.854896	0.813114	0.901206
3	Logistic Regression	0.789518	0.865179	0.793802	0.781564	0.806430
4	Boosted Decision Tree	0.891562	0.959495	0.890251	0.905595	0.875419

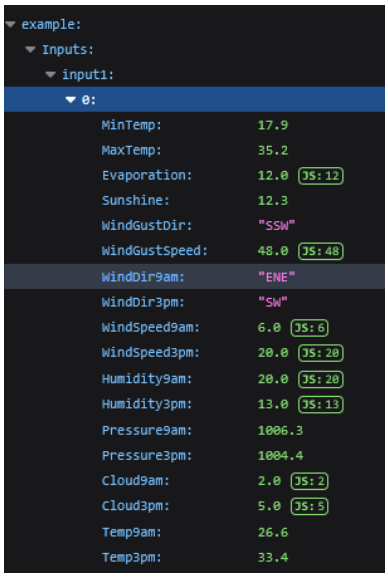
Slika 7: Rezultati algoritama nakon optimizacije

Vidimo kako nakon navedenih promjena rezultati evaluacija su više realni. Boosted decision tree je još uvijek algoritam s najboljim performansama i stoga će biti implementiran u API.

3.2. Način korištenja API-ja

API je razvijen kao web servis kroz Microsoft Azure Machine Learning Studio. Temelji se na REST arhitekturi koja koristi HTTP protokol za slanje i obradu zahtjeva. Zahtjevi i odgovori se šalju u JSON formatu koristeći POST metodu.

Primjer zahtjeva se može vidjeti na primjeru krajnje točke tj. "swagger URI" gdje je opisan oblik zahtjeva i odgovora koji API očekuje.



Slika 8: Primjer očekivanog oblika tijela zahtjeva za API

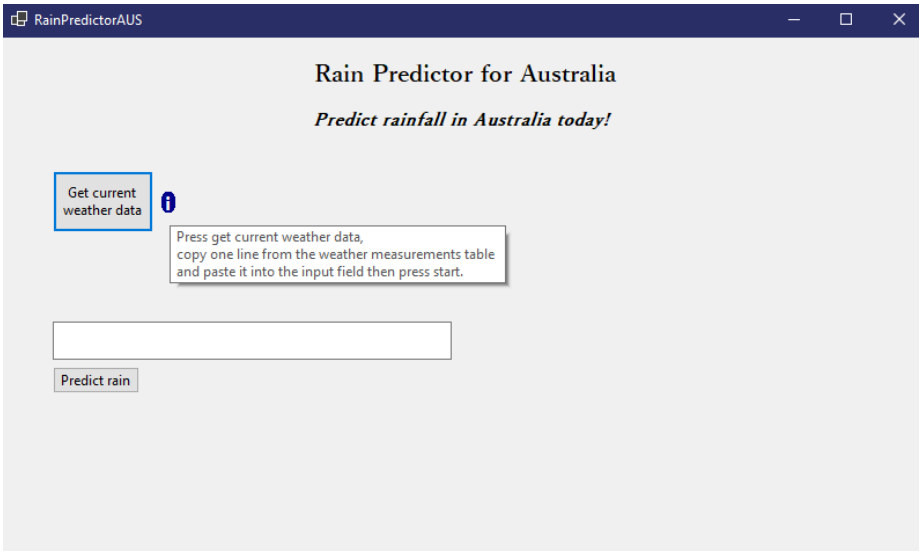
API se sastoji od jedne krajnje točke kojoj se šalje HTTP zahtjev koji u svom zaglavlju sadrži autorizacijski ključ koji je dan od Azurea i u tijelu zahtjeva ranije definirane podatke. Tijelo se sastoji od naziva stupaca i vrijednosti tj. u ovom slučaju vrsta mjerenja vremenskih uvjeta i njihovih vrijednosti koje koristimo za predikciju hoće li padati kiša.

Prediction result:
{"Results": {"WebServiceOutput0": [{"MinTemp": -0.6450953748222685, "MaxTemp": -1.5104326195583442, "Evaporation": -0.575011482282664, "Sunshine": -1.9368993208294474, "WindGustDir": "SSW", "WindGustSpeed": -0.22033311301235578, "WindDir9am": "WNW", "WindDir3pm": "SW", "WindSpeed9am": 0.3558034490605512, "WindSpeed3pm": -0.6206441836822549, "Humidity9am": 1.4812002423169608, "Humidity3pm": 1.7735531599288257, "Pressure9am": 0.807650341918505, "Pressure3pm": 0.6841901660390662, "Cloud9am": 7.0, "Cloud3pm": 7.0, "Temp9am": -1.3791353260708004, "Temp3pm": -1.3365134423683245, "Scored Labels": true, "Scored Probabilities": 0.763246817440545}]}}

Slika 9: Primjer odgovora APIa

Na gornjoj slici vidimo format odgovora APIa. Vraćaju se ulazni podaci koji su unutar modela modificirani tijekom predikcije tj. podaci su normalizirani kao ranije opisano. Bitan dio odgovora je "Scored Labels" i "Scored Probabilities" koji nam daju klasifikaciju hoće li padati kiša ili ne i koja je sigurnost predikcije.

3.3. Klijentska aplikacija



Slika 10: Prikaz korisničkog sučelja aplikacije

Aplikacija je izrađena za windows okruženje u obliku windows-forms aplikacije. U gornjoj slici vidimo korisničko sučelje. Dizajn je minimalan kako bi korisnik brže i efikasnije pristupio željenom servisu tj. njegovim informacijama. Kako bi korisnik znao kako koristiti aplikaciju pomakom miša na "i" simbol dobiva instrukcije korištenja.

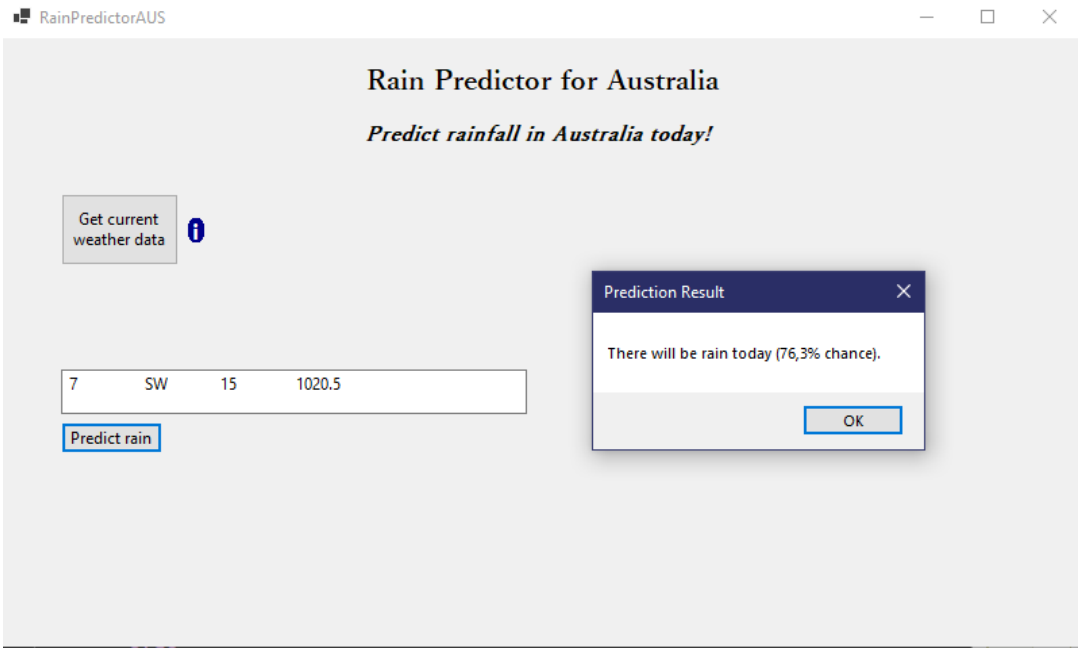
Sydney, New South Wales
August 2025 Daily Weather Observations

Most observations from Observatory Hill, but some from Fort Denison and Sydney Airport.

Date	Day	Temps Min °C	Temps Max °C	Rain mm	Evap mm	Sun hours	Max wind gust Dir	Max wind gust Spd km/h	Max wind gust Time local	9 am Temp °C	9 am RH %	9 am Cld 8th	9 am Dir	9 am Spd km/h	9 am MSLP hPa	3 pm Temp °C	3 pm RH %	3 pm Cld 8th	3 pm Dir	3 pm Spd km/h	3 pm MSLP hPa
1	Fr	8.5	13.0	9.6	3.0	0.0	SSW	39	15:15	8.8	93	7	WNW	20	1023.7	12.9	86	7	SW	15	1020.5
2	Sa	8.8	16.5	38.8	0.6	0.0	SE	70	20:27	12.1	95	8	ESE	13	1020.6	14.8	84	8	SE	30	1016.9
3	Su	12.1	17.1	17.0	4.6	0.8	ESE	69	01:08	15.6	88	8	S	26	1021.5	15.7	93	8	SSW	11	1021.1
4	Mo	11.5	19.0	20.0	3.6	6.7	S	31	00:15	13.6	98	6	WNW	17	1023.2	18.6	74	6	S	7	1020.5
5	Tu	10.6	22.9	2.2	2.4	6.7	W	28	22:39	11.6	99	3	W	17	1018.7	22.2	45	3	E	9	1015.0
6	We	10.5	19.5	0	2.8	9.6	W	44	12:43	13.1	59	2	W	22	1020.9	19.3	35	1	SW	15	1019.3
7	Th	9.7	17.6	10.2	3.2	1.3	SSE	41	11:22	10.8	97	7	WNW	19	1028.2	15.9	56	6	SSE	20	1028.2
8	Fr	9.7	17.9	0.2	2.2	5.4	SW	37	20:16	13.1	75	7	WNW	15	1033.1	16.3	66	8	S	22	1031.3

Slika 11: Primjer zapisa mjerenja

Pritiskom na gumb "get data" otvara se stranica s meteorološkim mjerenjima. Korisnik mora kopirati red u tablici tj. mjerenja za željeni dan te ih zalijepiti u unosno polje aplikacije. Naknadno pritiskom na gumb "predict" dobiva obavijest hoće li na taj dan padati kiša ili ne i koja je vjerojatnost toga. Provjerom povijesnih zapisa oborina u Australiji potvrđeno je da je toga dana padala kiša te da je aplikacija pravilno predvidjela kišu.



Slika 12: Prikaz predikcije kiše

4. Zaključak

Kod izrade projekta koji sadrži strojno učenje bitno je pripaziti na skup podataka koji se obrađuje. Bitno je osigurati da su podaci iskoristivi, da nemaju previše nedostajućih vrijednosti što bi moglo narušiti proces učenja. Bitno je da podaci sadrže dovoljno značajki koje su relevantne za predikciju ciljane variable i u slučaju klasifikacije da podatkovni skup sadrži podjednaku količinu svih klasa. Azure Machine Learning olakšao je proces prilagodbe podataka kao i testiranje i uspoređivanje modela. Također je pojednostavljen proces izrade web API-a i njegov deploy što omogućuje brzu i efikasnu praktičnu primjenu modela strojnog učenja. Unatoč jednostavnosti korištenja treniranje modela ponekad može potrajati ovisno o vrsti modela koji se trenira i količini alocirane procesorske snage.

5. Poveznice i literatura

Programskom je rješenju moguće pristupiti preko:

Programsko rješenje na GitHubu

[1] K.P.Murphy, Machine Learning: A probabilistic perspective, MIT Press, Cambridge, Massachusetts, SAD, 2012

[2] Sydney, New South Wales August 2025 Daily Weather Observations, dostupno na: https://www.bom.gov.au/climate/dwo/IDCJDW2124.latest.shtml

[3] Machine Learning Algorithm Cheat Sheet, dostupno na: https://learn.microsoft.com/en-us/azure/machine-learning/algorithm-cheat-sheet?view=azureml-api-1

[4] SMOTE component, dostupno na: https://learn.microsoft.com/en-us/azure/machine-learning/component-reference/smote?view=azureml-api-2

[5] Azure ML endpoint deployment basics, dostupno na: https://learn.microsoft.com/en-us/azure/machine-learning/tutorial-deploy-model?view=azureml-api-2